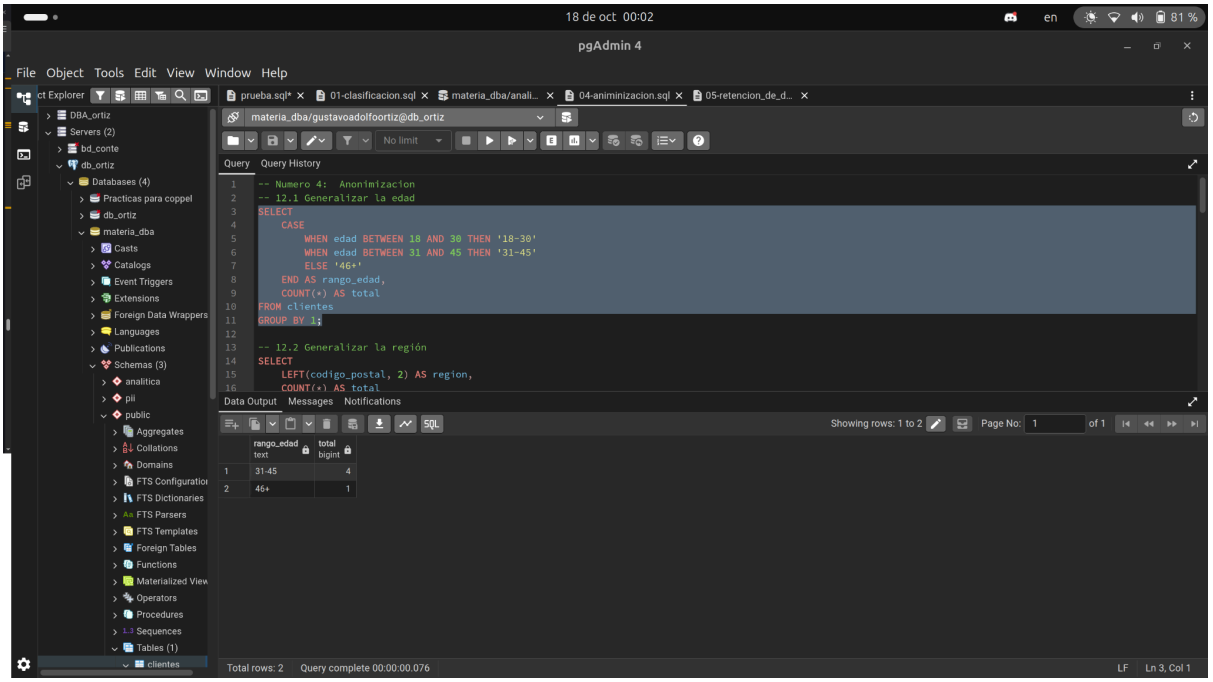
Alumno: Gustavo Adolfo Ortiz Orona

Actividad: Actividad 5 y 6

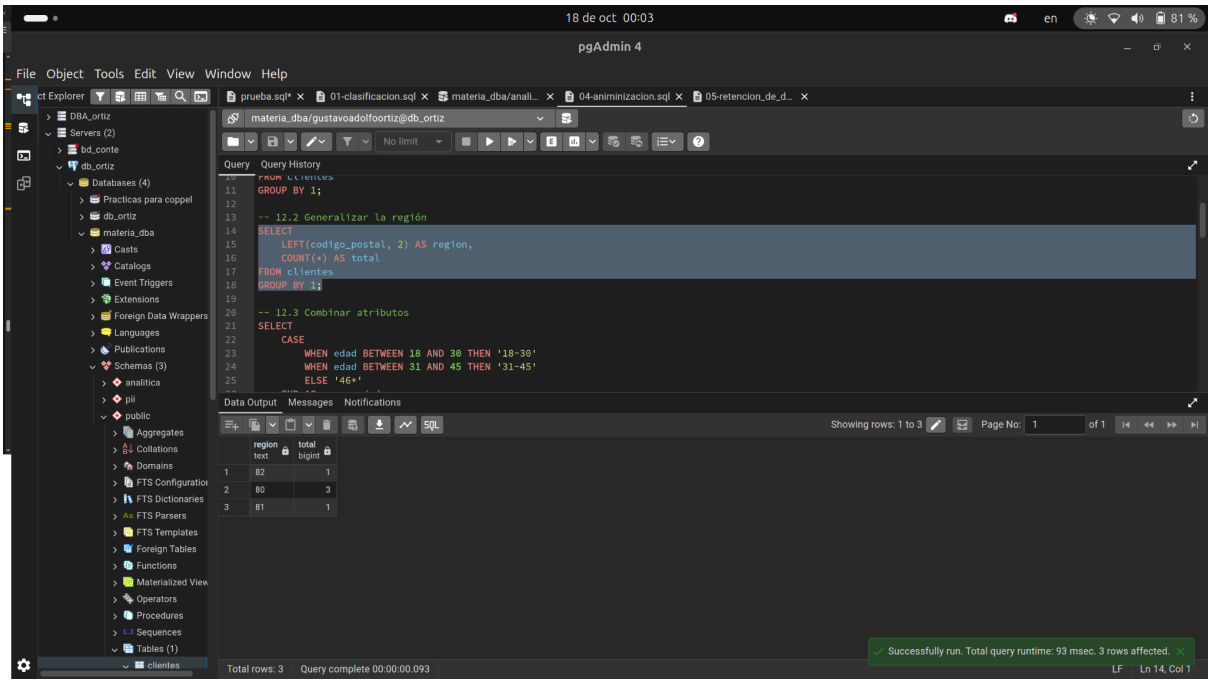
# 04 - Anonimización (anonymization)

## Evidencias Mínimas.

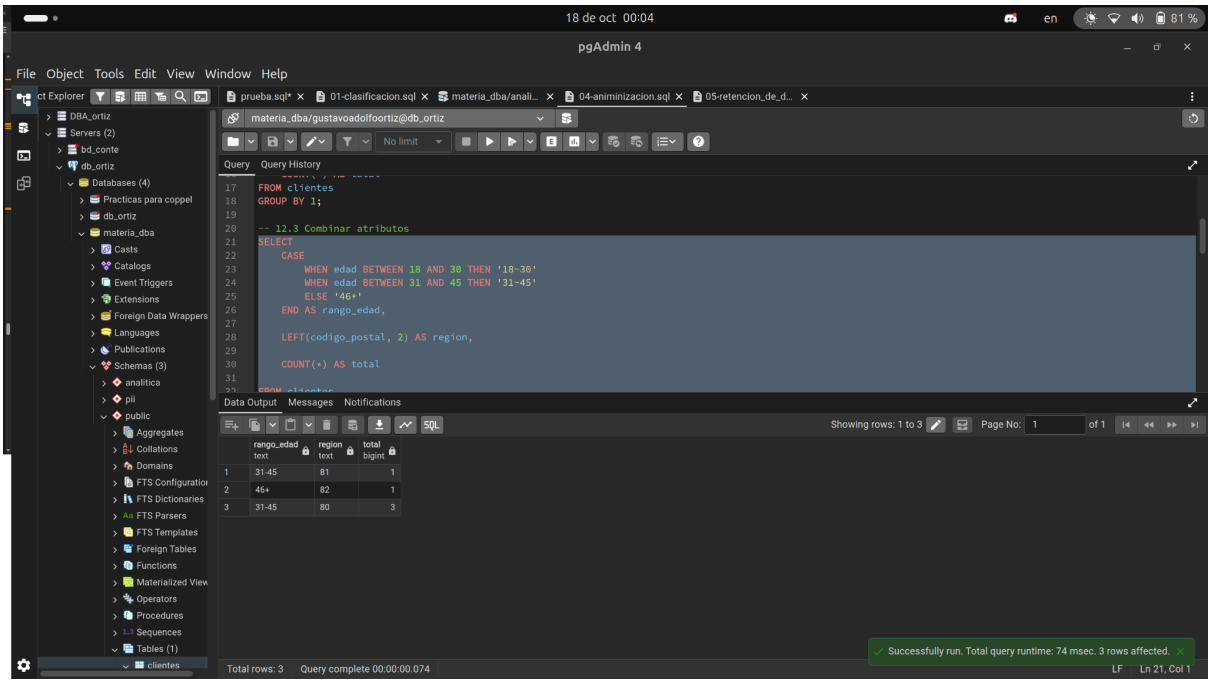
- Generalizar la edad



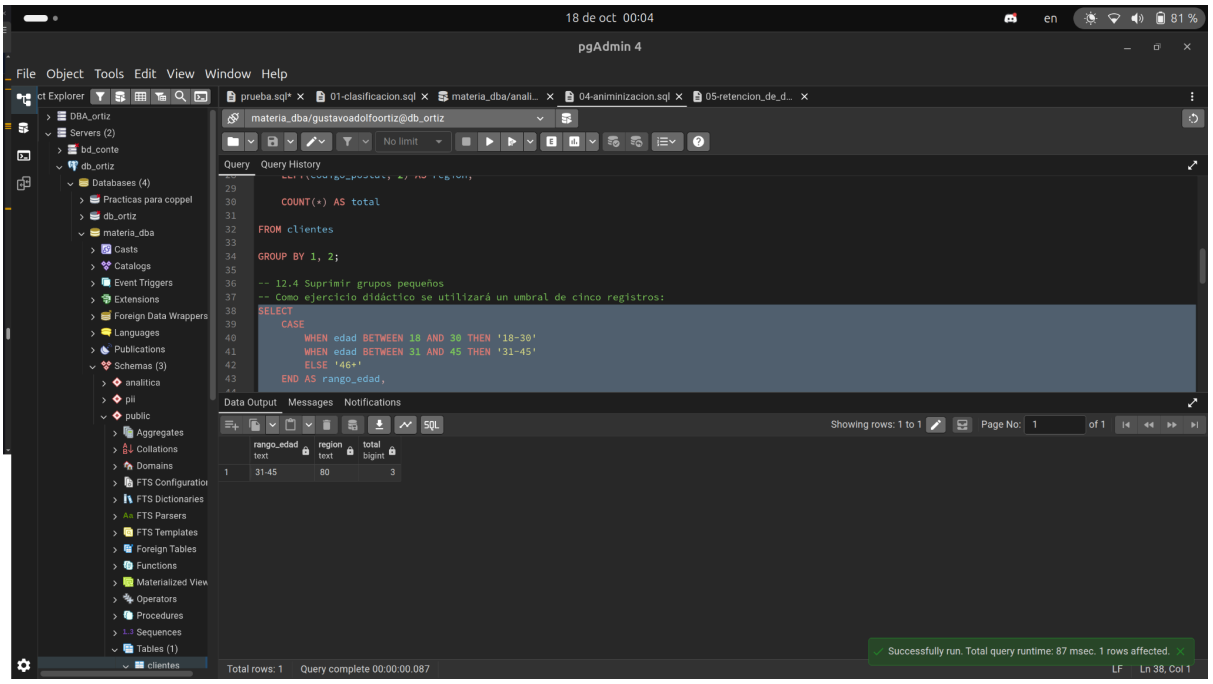

- Generalizar la región



- Combinar atributos




- Suprimir grupos pequeños




Preguntas:

**¿Qué identificadores directos fueron eliminados?**
Se dejaron de usar los identificadores directos, como el nombre del cliente, rfc, teléfono, correo y cualquier otro dato que permita reconocerlo directamente. Las consultas solo muestran la información agrupada, como rangos de edad, regiones y cantidades de clientes.
**¿Qué cuasi-identificadores permanecen?**
Permanecen la edad generalizada en rangos y la región obtenida a partir de los primeros dos dígitos del código postal.

**¿Qué combinaciones de atributos podrían reducir el anonimato?**
Con las combinaciónes de rango de edad, región y otros atributos, como género, ocupación o fecha de nacimiento, podrían reducir el anonimato.
**¿Qué sucede cuando un grupo contiene pocos registros?**
Cuando un grupo contiene pocos registros, aumenta el riesgo de identificación, debido a que es más fácil distinguir a las personas que pertenecen a él.
**¿Qué atributos deberían generalizarse?**
Los atributos que permitan distinguir demasiado a los clientes, como pueden ser los rangos de edad más amplios, agrupacion de los códigos postales en regiones más grandes y evitar fechas exactas de nacimiento.
**¿Qué información debería suprimirse?**
Se deberían suprimir los identificadores directos, como el nombre, teléfono, correo y rfc.
**¿Es correcto afirmar que el conjunto de datos es "100 % anónimo"? ¿Por qué?**
No es correcto afirmar que el conjunto de datos es 100 % anónimo únicamente porque se eliminaron los identificadores directos y se agruparon los registros. Todavía pueden existir cuasi-identificadores que, al combinarse con información externa, permitan reconocer a determinadas personas.

## Reto

Modificar la consulta anterior para reducir aún más el riesgo de reidentificación.
**Documentar:**
**Cambio realizado:**
Se ampliaron los rangos de edad de 18-30 y 31-45 a 18-35 y 36-50 y se cambió la región de los primeros dos dígitos del código postal a solamente el primer dígito. Se conservó el mismo filtro de HAVING COUNT(*) >= 5.
**Motivo:**
El propósito es reducir la precisión de los cuasi-identificadores. Si utilizo rangos de edad más amplios y regiones menos específicas, puede resultar más difícil distinguir a un cliente dentro del conjunto de datos.
**resultado obtenido:**
Esta consulta genera una tabla estadística con rangos de edad más amplios, regiones más generales y el número de clientes de cada grupo.
**Riesgo que se pretende reducir:**
Se busca disminuir el riesgo de reidentificación mediante la combinación de edad y ubicación del codigo postal.